

# Questão 1

Wellington Charles Lacerda Nobrega

18/04/2021

## 1. Estruturar uma fórmula para atribuir uma reputação a um estabelecimento $j$ do setor $k$ em um dia arbitrário $t$ a partir de todas as avaliações individuais:

Primeiro, vamos definir  $s_{t,j,k}$  como sendo o score médio da  $j$ -ésima firma individual do  $k$ -ésimo setor no dia  $t$ , assim, podemos calcular o score médio como:

$$s_{t,j,k} = \frac{\sum_{i=1}^{n_{t,j,k}} S_{t,j,k,i}}{n_{t,j,k}} \quad \text{onde } t = 0, 1, 2, \dots, N \quad (1)$$

em que  $n_{t,j,k}$  é o número de vendas da empresa  $j$  do setor  $k$  no dia  $t$  e  $S_{t,j,k,i}$  denota um score individual recebido pela  $j$ -ésima firma do  $k$ -ésimo setor no dia  $t$  pela  $i$ -ésima venda. Assim, o score médio ( $s_{t,j,k}$ ) retorna o valor médio das avaliações no dia da empresa  $j$ , do setor  $k$  no dia  $t$ . Para tornar as avaliações antigas menos relevantes e as mais novas mais relevantes na medida em que decorre o tempo, é necessário ponderar o score médio por um termo de decaimento exponencial que reflita a maior distância em um menor número. Assim:

$$sa_{t,j,k} = s_{t,j,k} \cdot \exp^{-\lambda t} \quad (2)$$

onde  $sa_{t,j,k}$  denota o indicador ajustado,  $\lambda$  é um escalar não-negativo, uma alternativa é denotar  $\lambda = \frac{1}{N}$ , em que  $N$  é o número total de dia decorridos.

## 2. Estruturar uma agregação para um determinado setor $k$ em um dia qualquer $t$ .

Vamos definir  $K_{t,k}$  como sendo o indicador agregado para o setor  $k$  no dia  $t$ . Para a agregação, será realizado uma ponderação de acordo com a importância relativa de cada  $j$ -ésima firma sobre o total de vendas do setor  $k$ . Para isso, aplicaremos uma ponderação  $\Omega_{j,k,t}$  para captar a importância relativa, onde, quanto maior for a participação da  $j$ -ésima firma sobre o total de vendas do  $k$ -ésimo setor, maior será o valor de  $\Omega$  para essa firma.

$$K_{t,k} = \frac{\sum_{j=1}^{m_{t,k}} sa_{t,j,k} \cdot \Omega_{j,k,t}}{m_{t,k}} \quad \text{onde } t = 0, 1, 2, \dots, N \quad (3)$$

onde  $m$  é a quantidade de empresas do setor  $k$  que foram avaliadas no dia  $t$ . A ponderação  $\Omega_j$  é dada por:

$$\Omega_j = \frac{n_{t,j,k}}{\sum_{j=1}^{m_{t,k}} n_{t,j,k}} \quad (4)$$

onde  $n_{t,j,k}$  (já foi definida anteriormente) é o número de vendas da empresa  $j$  do setor  $k$  no dia  $t$  e  $\sum_{j=1}^{m_{t,k}} n_{t,j,k}$  é o total de vendas do setor  $k$ . Destaca-se que  $\sum_{j=1}^{m_{t,k}} \Omega_{j,k,t} = 1$ .

### 3. Construir um método para um indicador agregado de reputação em um dia qualquer $t$ .

Defina  $I_t$  como sendo o indicador que agrega o score setorial. Novamente, realizaremos uma ponderação de acordo com a importância relativa do  $k$ -ésimo setor sobre as vendas totais em um dia  $t$ , de acordo com:

$$I_t = \frac{\sum_{k=1}^{q_t} K_{t,k} \cdot \Theta_k}{q_t} \quad \text{onde } t = 0, 1, 2, \dots, N \quad (5)$$

em que  $q_t$  é a quantidade total de setores avaliados no dia  $t$ . A ponderação  $Z_k$  é dada por:

$$\Theta_k = \frac{n_{t,k}}{n_t} \quad (6)$$

onde  $n_t$  é o total de vendas e  $n_{t,k}$  denota o total de vendas do setor  $k$  no período  $t$ .

### 4. Como incorporar informações qualitativas dos *reviews*?

Nesta etapa do indicador é possível aplicar técnicas de Análise de Sentimentos para que seja possível parametrizar as informações qualitativas em informações quantitativas e, então, agregá-las ao índice. A Linguagem Natural de Processamento (NLP) é um ramo da linguística e computação que investiga os problemas de compreensão das línguas naturais humanas a partir do aprendizado de máquina. Essa etapa não é trivial, mas é extremamente fascinante. De uma forma estruturada:

**Passo 1:** O primeiro passo na incorporação das informações qualitativas no indicador é a limpeza das informações contidas nos *reviews*. É necessário que seja aplicado técnicas de *text mining* para a remoção de espaços duplos, *stop words*, pontuação, números, quebra de linhas e padronização de todos os caracteres para minúsculo. O objetivo final é deixar apenas as informações que de fato sejam relevantes e possam ser traduzidas em informações.

**Passo 2:** O segundo passo nesse processo é a escolha de um dicionário de palavras que seja capaz de capturar as informações relevantes no nosso *corpus* de *reviews*. Existem diversos dicionários de palavras pré-classificadas como sendo capazes de expressar o sentimento “negativo” ou “positivo”. Por exemplo: *reviews* que contenham as palavras “ruim”, “mal” ou “péssimo” podem estar associados a clientes insatisfeitos, gerando um sentimento negativo. Enquanto *reviews* que contenham palavras como “excelente”, “ótimo” ou “bom” podem estar associados a clientes satisfeitos, gerando um sentimento positivo. Ademais, é necessário observar cuidadosamente palavras que possam efetivamente representar sentimento ambíguo quando avaliada em setores diferentes.

**Passo 3:** O terceiro passo seria a parametrização das informações qualitativas e posterior inclusão das informações no indicador de reputação. Para isso, é importante que a alternativa de parametrização seja independente de qualquer tipo de escala subjetiva. Ou seja, o algoritmo que transformará as informações qualitativas dos *reviews* em informações quantitativas deverá de alguma forma ser baseado na frequência ponderada com a qual as palavras vão aparecendo nos *reviews*. Uma alternativa, é a seguinte:

$$\text{sentimento}_t = \frac{\sum \text{Palavras Positivas} - \sum \text{Palavras Negativas}}{\sum \text{Palavras Positivas} + \sum \text{Palavras Neutras} + \sum \text{Palavras Negativas}} \quad (7)$$

A alternativa acima pertence ao intervalo -1 e 1, ou seja,  $\text{sentimento}_t \in [-1, 1]$ . Quando  $0 \geq \text{sentimento}_t \leq 1$  tem-se um sentimento positivo; neutro quando  $\text{sentimento}_t = 0$  e negativo quando  $\text{sentimento}_t < 0$ . Ao se ponderar o indicador com a abordagem de sentimentos, em tese, seríamos capazes de levar as informações qualitativas contidas nos *reviews* em consideração na construção do indicador de reputação.